

半導體廠務 PHM 前沿產品鏈設計綜合報告

介紹與背景

現代半導體晶圓廠的**廠務設施**（Facility）涵蓋了多種關鍵系統（例如空調HVAC、冷卻水系統、超純水、廢氣處理與配電等），其可靠運行對於生產穩定至關重要。為了防止突發停機和優化維護成本，**設備健康管理與預測維護**（PHM, Prognostics and Health Management）逐漸成為廠務管理的核心策略¹。PHM 方法透過**感測設備運行參數**、**偵測異常徵兆**、**診斷故障原因**、**預測剩餘壽命**，最後提供**預防維護決策建議**，形成一條龍的智慧維護產品鏈。本報告針對半導體廠務PHM產品的前沿設計進行綜合分析，從感測器部署、異常偵測、故障診斷、預後分析（剩餘壽命預測）到維護決策支援，逐一探討最新的人工智慧模型與傳統方法（作為對照基準），發掘各環節的技術細節與挑戰。同時，我們考慮**多層架構**（Edge/Server/Cloud）的實現、資料多樣性與模型泛化能力，以及**KPI儀表板**用於量化方案效益。以下將依照產品鏈各步驟展開說明，每個關鍵點並引用近五年頂尖期刊/會議的相關研究成果來支持設計方向。

感測器佈署與資料收集

感測器網絡是PHM產品鏈的基石。半導體廠務涵蓋廣泛的參數類型，需要部署多種感測器：例如溫度、濕度、壓力、流量、震動、電流電壓、轉速、濃度等，以**全天候監測**空調機組、冷卻塔、鍋爐、泵浦、壓縮機、配電盤等設備的健康狀態。由於感測器數量龐大且分散，資料採集系統需具備**即時性**與**可靠性**，並能處理異質資料來源。在資料層面上，主要挑戰包括：感測器校準偏差、漂移、故障或丟失資料，多感測器資料融合，以及資料品質控制等。

特別是**感測器漂移與故障校準**問題，會直接影響後續異常偵測與預測的準確性。最新研究已提出先進的方法來解決此問題。例如，Hu 等人（2025）在 Building Simulation 期刊發表了「An enhanced multi-sensor calibration method for HVAC systems without prior knowledge of fault types」²。該研究針對大型建築空調系統中的多個感測器，在**未知故障類型**的情況下進行自動校準。其方法採用區間滑動窗口演算法來**識別並校正感測器的偏移（bias）和漂移（drift）**軟故障，並調整窗口大小以優化校準效能³。在香港一棟大型建築的冷凍機組實驗中，包含8個感測器（其中3個為漂移型故障）的情境下，校準結果對於偏移型故障達到100%的準確率，對於漂移型故障也達到95%的準確率⁴。這項增強校準方法在漂移校正上相較既有高維校準方法和改良模擬退火法分別提升了87%和34%的表現⁴。由此可見，前沿技術已能有效解決感測器長期漂移導致的測值不準問題，確保資料可靠性。

此外，為了**考慮所有相關感測器**並支援多樣化的資料來源，我們的產品將採用**模組化感測節點**設計，支持各類工業通訊協議（如 OPC UA、MODBUS、BACnet 等），將現有廠務監控系統的資料整合進來。在Edge端初步進行資料清洗與壓縮（如濾除明顯異常或插值補全缺失值），然後透過安全網路傳送至伺服器/雲端進行深度分析。總之，在感測環節我們不僅需**全面覆蓋**廠務相關參數，還要能克服感測器誤差與故障影響，為後續智能模型提供高品質的數據基礎。

異常偵測（Anomaly Detection）

有了可靠的感測數據後，第一步是進行**異常偵測**，即從大量即時資料中自動發現偏離正常運行模式的徵兆。廠務系統的異常可能包括設備運行參數的異常波動、效率下降或能耗異常等。挑戰在於：1) 正常運行狀態可能隨負載和環境而變化，需區分合法變化與異常；2) 通常缺乏標記好的異常範例（因故障稀少），使得監督式學習困難。因此，最新研究多採用**非監督或半監督學習**方法，利用正常數據學習模型，再偵測偏差。傳統方法如**主成分分析(PCA)**、**高斯混合模型(GMM)**、**One-Class SVM**以及**管控圖**等已廣泛應用，但在高維非線性資料面前

表現有限。我們將引入**深度學習**的異常檢測技術作為前沿方案，例如**自編碼器(Autoencoder)**、**變分自編碼器(VAE)**、**深度高斯混合**，以及**深度概率模型**等，用來自動學習資料的低維表示並捕捉複雜關係。

具體而言，一項最新研究展示了如何在**極少標註資料**的情況下提升異常檢測效能：Huang 等人 (2024) 於 SAFEPROCESS 國際會議發表了「Time-series few shot anomaly detection for HVAC systems」⁵。該方法面對建築空調 (HVAC) 系統中異常標記樣本稀缺的難題，提出了一種**少樣本遷移學習**方案。作者使用長短期記憶網路自編碼器 (LSTM-AE) 模型，先在**源域** (資料充足的系統) 的正常運行資料上訓練，再將模型**少量調適**到**目標域** (資料有限的新系統)⁶。特別的是，該方法只需要源域與目標域的少量**正常運行**資料即可，不需大量故障樣本，透過**few-shot domain adaptation**實現跨系統的異常偵測知識遷移⁶。實驗結果顯示，相較於傳統的非監督方法，這種帶有**少樣本域自適應**能力的深度自編碼器在多種HVAC故障場景下能更準確地識別出異常⁷。因此，我們的異常偵測模組將優先考慮類似理念：使用深度自編碼器學習正常行為模型，並結合遷移學習或少樣本學習以增強模型在新設備、新環境下的適應性。如果有標註的異常樣本，可進一步採用監督式的**異常分類**模型 (如將異常檢測轉化為分類問題，應用CNN/LSTM進行多類別故障徵兆辨識)，並以傳統方法如管控圖、ARIMA預測殘差檢測作為基準比對，確保我們的方法在偵測靈敏度和誤報率上具有優勢。

故障診斷 (Fault Diagnosis)

當異常被偵測到後，下一步是**診斷**其背後的故障原因，即識別「是哪種故障發生了、發生在何處」。在廠務系統中，可能的故障包括傳感器失靈、閥門卡滯、管路泄漏、馬達軸承磨損等多種類型。傳統上，工程師依賴經驗和**規則庫/專家系統** (如FMEA故障模式影響分析表) 來定位故障。但這種**知識本位**方法需要人工列舉所有故障模式，難以及時應對新型或複雜故障。為此，現代PHM引入了**資料驅動**的故障診斷技術，包括機器學習和深度學習模型，直接從感測器數據中學習故障類型的**判別特徵**。例如，傳統的**支持向量機(SVM)**、**隨機森林**以及**kNN**分類器曾用於設備故障診斷基準；而新的趨勢是使用**卷積神經網絡(CNN)**提取時序或頻譜特徵、**長短期記憶網路(LSTM)**捕捉時間依賴，甚至**圖神經網絡(GNN)**來建模多部件之間的關聯故障。深度學習方法已在許多HVAC及旋轉機械的故障診斷中取得優異表現⁸⁹。

主要挑戰在於：故障類別眾多且各設備間差異大，訓練資料可能非常不平衡 (正常工況數據遠多於故障數據)，甚至某些新設備沒有歷史故障數據。為了讓診斷模型具有**泛化能力**，減少對大量標註故障數據的依賴，我們關注**領域自適應(domain adaptation)**與**遷移學習**技術在故障診斷上的應用。Azamfar 等人 (2020) 在 IEEE Transactions on Semiconductor Manufacturing 提出的「Deep learning-based domain adaptation method for fault diagnosis in semiconductor manufacturing」即是一個代表性成果。該研究針對半導體製造中的品質檢測/故障診斷，提出利用**深度學習結合領域自適應**的方法，來實現**跨設備、跨製程的故障診斷泛化**。具體而言，他們透過**對抗式神經網絡** (例如DANN, Domain-Adversarial Neural Network) 對不同資料域之間的特徵分佈進行對齊，減少源域 (有標註資料) 與目標域 (無標註新資料) 之間的差異，從而使模型在新域上也能準確分類故障¹⁰¹¹。實驗結果顯示，該深度遷移診斷方法在新的製程條件下仍能保持高診斷精度¹²。這表明透過領域適應技術，可以顯著提升故障診斷模型的適應力，進而滿足「模型領域不拘」的產品需求。

除了深度學習，本產品也將結合**可解釋AI (XAI)**技術，幫助工程師理解診斷結果。例如利用**SHAP值**或**注意力機制**權重，突出對某種故障判斷最有貢獻的關鍵參數，增強模型的可解釋性和工程信任度。傳統的基於**物理機理模型** (如基於熱力學/流體力學的一階原理模型) 也可與資料驅動方法融合，形成**混合診斷**手段：例如建立HVAC的熱力迴路模型以輔助判斷是感測器故障還是實際設備性能下降。總的來說，在故障診斷環節，我們將採用**深度學習分類與遷移學習**的先進方法，並保留傳統專家系統和物理模型作為輔助與基準，確保診斷的**準確性**與**廣泛適用性**。

預後分析與剩餘壽命預測 (Prognostics & RUL Prediction)

有了對當前故障的診斷，本產品鏈更進一步的重要功能是**預後分析**，即預測設備從現在起在未來運行中的健康狀態變化，尤其是估計**剩餘可用壽命 (RUL, Remaining Useful Life)**。對廠務設備而言，能提前預測某關鍵部件 (如馬達軸承、濾芯、閥門) 的剩餘壽命，可以讓維護團隊有計畫地安排更換，避免非計畫停機。預測維護決策的效果極大依賴於RUL預測的準確度和可信度。預後分析的挑戰在於：需要長期的歷史數據來觀察**退化趨**

勢，且退化過程可能受到負載變化、環境因素影響而**非線性**、**高噪聲**。傳統預測方法包括**統計回歸**（如線性/指數退化模型）、**卡爾曼濾波**、**粒子濾波**、以及利用已失效部件歷史的**魏伯分布**分析等。然而，這些方法往往需要指定明確的退化指標或假設退化路徑，靈活性有限¹³。

深度學習的興起為RUL預測帶來了**端到端學習**的可能。透過讓模型自動從多維感測器序列中學習退化特徵，可以避免人工選取指標的偏差¹³。Li 等人（2024）在 Scientific Reports 發表的「A method for predicting remaining useful life using enhanced Savitzky–Golay filter and improved deep learning framework」就是一個良好範例¹⁴。他們提出一個**多通道、多尺度的深度學習**框架：首先運用改進的**Savitzky–Golay 濾波**對原始感測序列進行平滑和去噪處理，應對工業大數據中噪聲和劇烈波動¹⁵。接著，模型結合**卷積神經網絡(CNN)**與**長短期記憶網絡(LSTM)**兩種結構，CNN用於提取多通道感測資料中的空間局部特徵模式，LSTM則擅長捕捉時間序列上的長期依賴關係，最終融合兩者輸出來進行RUL的預測¹⁵。這種CNN+LSTM架構能夠學習傳統方法難以手動提取的**分層次特徵**，對複雜運行資料提供更精確的壽命預測。在C-MAPSS航空引擎退化資料集上的測試顯示，該深度框架在動態工況下比經典機械學習算法取得更小的預測誤差，對單一故障模式的預測特別準確¹⁶。雖然在同時存在多種故障模式的情況下表現尚有提升空間，但整體上明顯優於傳統算法¹⁷。

除了上述混合架構，前沿研究還嘗試了**各種深度學習模型**來提升RUL預測效果，例如：引入**注意力機制**的卷積網絡以動態關注關鍵退化區段¹⁸、將**Transformer**應用於長序列資料、以及結合**圖神經網絡**建模多部件相互影響。一些研究更結合**物理知識**，形成物理引導的神經網絡（PINN）或混合模型：例如將退化的物理模型融入神經網絡結構，利用自注意力機制強化，應用在飛機引擎和電池壽命預測上取得了更高的準確度¹⁹²⁰。總之，我們預後分析模組將採用**深度學習為主**、輔以**物理模型**的方式。一方面利用**深度神經網**在資料中自動學習複雜劣化模式的能力，另一方面確保預測結果的**物理合理性**與**可解釋性**（例如透過模型內建的物理約束）。另外，我們也將對預測給出**不確定度估計**（例如透過蒙地卡羅dropout或貝葉斯神經網絡），讓維護人員瞭解預測的可信區間。最終，RUL預測結果將作為後續維護決策的重要依據。

維護決策與優化 (PM Decision Making)

有了對當前狀態的診斷和對未來壽命的預測，我們便可進行**預防維護決策**（Preventive Maintenance Decision）。這一環節旨在回答：**何時**以及**如何**進行維護，才能最低成本地保證設備可靠運行。對半導體廠務而言，維護決策涉及安排維護窗口（避免干擾生產）、備品備件管理，以及對多台設備維護順序的優化等。傳統上，維護策略有**定期預防維護**（如每月檢修）、**事後維修**（故障後修復）和**狀態基礎維護**（依監測狀態觸發）。PHM的引入使我們可以實現**預測維護**，即根據預測的故障風險動態安排維護時機。這實質上是一個**優化決策**問題，需要在**降低故障風險**與**節約維護資源**之間取得平衡。

現代研究中，一個有力的工具是**強化學習 (Reinforcement Learning, RL)**。RL演算法讓代理(agent)透過「與環境互動，不斷試錯」學習決策策略，特別適合解決傳統方法難以顯式建模的複雜維護調度問題。Rodríguez 等人（2022）在 Robotics and Computer-Integrated Manufacturing 刊登了「Multi-agent deep reinforcement learning based Predictive Maintenance on parallel machines」的研究²¹²²。該研究針對工廠中多台平行機台的維護調度，提出一種**多智能體深度強化學習**框架。具體而言，他們構建多個RL智能體，部分觀察各機台的狀態（如健康指標、運轉情況），共同學習一個**協同維護策略**²³。此策略能根據實時狀態動態決定**何時**為哪台機器安排維護，以及指派哪個技能匹配的技師去執行²⁴。在不確定的故障發生情況下（隨機多機台故障），RL智能體透過不斷試錯，學會了比傳統**預防性維護**（定期保養）或**事後維修**更優的策略²³。實驗結果顯示，所學得的維護政策相較於傳統策略在**防止故障發生**和**減少停機時間**方面性能提升了約75%²⁵。也就是說，透過RL優化可以大幅降低意外停機，同時有效調度人力資源。

基於此成果，我們的PM決策模組計畫採用**深度強化學習**來實現**維護策略優化**。在架構上，可將每類設備或每個子系統的維護決策視為一個智能體，狀態包含設備健康（來自前述診斷/預測）、運行工況以及維護窗口限制等；動作為安排或延後維護的決定。透過與模擬環境反覆互動（可利用我們的**數位分身**模組進行環境模擬，詳見後述），智能體將學習在**最小化成本**（維護人力/備件/停機損失）與**限制故障風險**之間的最優折衷策略。當然，在實際部署前，我們會確保該策略遵循工程安全規範，不會因追求成本而忽略必要的檢修。此外，我們也會提供一套**傳統維護計劃**演算法作為對照，例如基於**優先級規則**或**整數規劃**的方法。比如，可建立一個以RUL

預測為輸入的**優化模型**（混合整數規劃），以最小化預計停機和維護成本來排程未來一段時間的維護任務。這種傳統優化方法相對透明，可用於驗證RL策略的有效性，確保我們的AI決策確實優於或至少不劣於現有最佳實踐。

總而言之，透過融合**深度強化學習與優化演算**，我們的產品將提供智能化的維護決策支援，協助工程團隊在恰當的時機執行恰當的維護措施，達到降低故障率與維護成本的雙重目標。

資料多樣性與模型泛化

半導體廠務系統種類繁多，包括暖通空調、氣體供應、真空系統、冷卻水、電力等，每一類系統的動態特性和故障模式各異。此外，不同晶圓廠之間設備型號、運營條件也有所不同。因此，我們的PHM產品需要具備**強健的泛化能力**，能夠在**不同設備、不同場域**中有效運作，而不必為每個新場景從零開始重新開發模型。為達成這一目標，需要在研發階段充分考慮**資料多樣性**和**遷移學習**。

首先，我們將建立一個**多樣化的訓練資料庫**。除收集實際廠務設備的歷史數據外，還可利用**資料增強**和**模擬數據**來拓展樣本空間。Somu & Dasappa (2024) 在其IntelliPdM框架中使用了 SMARTHome 合成資料產生器，基於有限的實測數據來**生成大量虛擬機台健康資料**，涵蓋各種可能的故障場景²⁶²⁷。同理，我們也將採用數位建模或蒙地卡羅模擬方法產生不同負載工況、環境條件下的**合成故障數據**。這不僅可以彌補真實數據中某些故障類型的缺乏，還能提升模型對罕見情況的感知。在模型訓練時，加入多樣化的資料有助於模型學習更普遍的特徵表示，減少對單一場域特性的過擬合。

其次，在算法層面，我們大量應用**遷移學習**與**領域自適應**技術（如前述異常檢測和故障診斷環節已介紹）。例如，可先在**跨行業的大規模設備運行數據**（如公共資料集）上進行模型的**預訓練**，學習通用的特徵表示，然後在目標晶圓廠的少量資料上**微調**。這種預訓練-微調策略已被證明能有效提高小樣本場景下的模型性能。此外，針對不同設備類型，我們考慮採用**多任務學習**或**元學習 (meta-learning)** 的框架：讓模型在訓練時同時學習多個相關任務（例如不同設備的故障預測），迫使模型提取能在不同任務間共享的高級特徵；或者透過元學習，使模型快速適應新任務（新設備）的能力增強。

值得一提的是，Huang (2024)⁶ 和 Azamfar (2020)的研究正是我們加強模型泛化的靈感來源：前者透過**少樣本學習**實現不同建築HVAC系統之間的異常檢測遷移，後者透過**對抗式域適應**達成半導體機台之間的故障診斷泛化。這些方法都將在我們的產品研發列表中重點探討。我們計畫將類似的方法融入各子模組，並進一步研究**聯邦學習**在跨工廠模型訓練中的應用（即在保障不同廠數據隱私的前提下，協作訓練一個更通用的模型）。

簡而言之，為確保產品的「**可泛化**」效應，我們從資料收集、模型訓練到部署的全流程都會融入讓模型**見多識廣**的設計。這將確保我們的一條龍PHM解決方案可以適應多種半導體廠務情境，具備跨設備、跨場域的可靠表現。

系統架構：Edge-Server-Cloud 協作

本產品鏈將採用**多層分散式架構**來兼顧**即時性**與**全局分析能力**。具體而言，我們設計 Edge（邊緣）、Server（現場伺服器）與 Cloud（雲端）三個層級，各司其職、協同工作：

- **Edge層**：由部署在現場設備附近的工業電腦或智慧感測節點組成。Edge層負責資料的初步處理和低延遲任務，例如即時異常偵測和緊急控制。由於異常偵測模型相對輕量（例如自編碼器重建誤差判斷）且需要毫秒級響應來觸發緊急停機或報警，我們可將部分異常偵測算法下放到Edge執行。一旦Edge端偵測到重大異常，可立即就地執行安全措施（如關閉閥門），同時通知上層。Edge層的運算也減少了原始數據向上傳輸的頻寬壓力，通過先行聚合或壓縮，將重要的特徵或事件上報。

- **Server層**：部署在廠內機房的中央伺服器或閘道器。這一層匯集多個Edge節點上傳的資料，進行**進一步分析與臨近決策**。Server具有比Edge更強的算力，可部署較複雜的模型（如診斷和預測模型）。由於在廠區內網，Server層仍可較低延遲地與Edge互動。它可以對多台設備的狀態進行**綜合評估**，例如相關設備的故障聯動診斷。同時，Server層可充當資料緩衝和過濾，將關鍵的狀態指標和歷史資料同步到雲端。
- **Cloud層**：部署在雲端平台（或公司數據中心），負責**全局數據存儲、深度模型訓練與決策支援**。雲端擁有彈性算力，可用於訓練複雜的深度學習模型（例如基於歷史大數據的不斷自我優化）。雲端也托管**決策支援系統和管理者儀表板**（詳見下節），供用戶透過網頁介面訪問。當Server層上傳設備健康指標後，雲端的模型（如維護決策優化、長期趨勢預測）會運行，並將結果下發給現場管理人員。雲端還可整合跨不同廠區的數據，以支持**企業級的維護優化**。

這種邊緣-雲協同框架已在文獻中證明有效，例如 Somu & Dasappa（2024）提出的 IntelliPdM 架構即是一個端到端IIoT預測維護框架，採用了**Edge-Cloud協同實現資料處理與決策**²⁸。IntelliPdM在邊緣收集**異質實時資料流**（感測器、攝影機等），在雲端執行智能故障診斷和維護排程，通過API和互動式儀表板提供故障警示和維護建議²⁸。該框架在歐洲與新加坡的真實製造環境中驗證了其**準確可靠的故障診斷能力**²⁹。我們的系統架構與其理念一致，即充分利用Edge即時性與Cloud全局性的優點³⁰²⁶。特別地，在安全性和可靠性方面，多層架構意味著即使雲端連線暫時中斷，Edge/Server層仍可本地運行關鍵功能，不影響基本監控和緊急保護。同時，敏感資料可在本地預處理，僅上傳統計特徵到雲端，以保護數據隱私。

架構實現上，我們將採用容器化技術（Docker/Kubernetes）來部署各層應用，方便升級與擴展。在Edge和Server層實現**輕量級推理服務**（如ONNX Runtime部署訓練好的模型），在雲端實現**大規模資料湖和模型訓練管線**。整體架構將遵循工業4.0標準，確保互操作性與資訊安全。我們也將建立**訊息總線**實現各層事件推送，如MQTT/AMQP消息系統，保證異常和決策能實時傳遞到需要的地方。通過上述多層架構，我們的PHM產品既能滿足現場工程師的即時需求，又能從全局出發優化維護策略，體現雲端智能與邊緣實時的結合。

儀表板與關鍵績效指標 (KPI Dashboard)

為了讓管理者和工程師直觀了解PHM系統帶來的效益，我們將設計一套**KPI儀表板**作為產品前端界面。這個儀表板將匯總展示各項關鍵績效指標，包括即時設備健康狀態、預測故障風險，以及長期的維護效益分析。以下是一些核心的KPI和功能構想：

- **設備健康指數**：用圖表或健康分數指示每台關鍵設備當前的健康狀況（可綜合異常偵測得分、故障概率等計算）。健康指數若低於門檻則高亮警示，工程師可點擊查看詳情。
- **剩餘壽命與維護窗口**：對於重點部件，顯示預測的RUL分佈以及建議的維護時間窗。例如某水泵軸承的RUL預測為20天，則儀表板可建議在未來2週內安排更換，並以甘特圖形式標出建議維護時段。
- **異常/故障警報**：實時列出當前檢測到的異常事件，標明時間、設備、異常類型和嚴重程度。對已診斷出的故障，提供故障類型和可能原因的說明（結合知識庫）。這些警報也可配置推送通知。
- **維護決策建議**：基於RL/優化結果，儀表板可以呈現未來維護計畫建議。例如下週預計對哪些設備做維修，每項維護的預計耗時和所降低的故障風險。管理者可以在介面上調整或批准建議計畫。
- **歷史績效分析**：量化PHM系統投入後帶來的改進，例如「**未計畫停機次數**下降了多少」、「**平均維修間隔MTBF**延長了多少」、「**維護成本節省比例**」等¹。例如，我們可以比較導入PHM前後，設備故障次數降低了X%，整體設備可用度提升了Y%。正如Omron的報告提到的，應用PHM可提高設備可用率並降低維護成本¹。這些指標將以報表和圖形呈現，以便向高層證明專案價值。

- **能源與效率KPI**（延伸目標）：廠務系統往往也關注能源效率，因此儀表板可集成能耗監測，顯示因預測維護避免故障後的節能效果。例如HVAC保持良好工況降低了耗電。另外也可展示碳排放減少等ESG相關指標，提升方案附加價值。

儀表板的設計將**以使用者為中心**，提供交互式的體驗。例如，可讓使用者自行篩選時段、設備查看趨勢，或模擬如果推遲某次維護會有何風險。我們亦會確保界面簡潔易讀，利用**可視化圖表**（折線圖、儀表盤、熱力圖等）來呈現複雜數據，使工程師在3~5秒瀏覽內就能抓取重點。

特別地，儀表板將做為**PHM系統的回饋機制**：透過持續展示KPI，我們可以和用戶一起量化系統效益，逐步調整優化演算法。例如，若某類預測常出現偏差，可在界面中提示進一步校正模型或增加感測器。另外，長期累積的KPI數據也可反饋給我們的模型訓練，以**閉環改進**PHM效果。

總而言之，KPI儀表板不僅是顯示資訊的窗口，更是讓PHM產品和使用者互動、展示價值的關鍵模組。我們期望藉由精心設計的儀表板，讓PHM方案的效果一目了然，使管理層和操作層都對系統產生信心和黏著度。

數位分身技術（Digital Twin）*分支探討

雖然數位分身並非目前工業產品的主流配置，但作為前沿趨勢，我們將其列為研發團隊可探索的**技術分支**之一。**數位分身（Digital Twin）**指為物理設備建立一個高保真的數位化虛擬模型，並通過實時感測數據將物理-虛擬系統連結同步³¹³²。在預測維護領域，數位分身可用於**模擬實驗與預測分析**：透過在虛擬環境中重現設備運行狀態，進行各種假設情景的測試（如特定部件劣化加速，環境條件變化等），從而提前預知可能的故障及最佳維護時機。

近年的研究概述了數位分身結合預測維護的優勢。例如 Zhong 等人（2023）在 Heliyon 刊物發表了「Overview of predictive maintenance based on digital twin technology」的綜述³³。該文指出，數位分身式的預測維護（PdM-DT）具有幾項關鍵特性：其一是**實時感知**，即透過埋置的感測器和IoT裝置不斷收集設備運行參數（溫度、壓力、振動等），並即時餵入數位模型，使虛擬雙胞胎與實體設備**同步更新**。這讓數位分身始終反映設備當前狀態，而非依賴預先設定的固定模型。其二是**預測分析能力**，數位分身結合歷史數據和即時模擬，可在線進行**故障預測和RUL估計**，找出潛在異常的早期跡象。除此之外，數位分身還允許進行**虛擬試驗與優化**：例如在虛擬環境中嘗試不同的維護方案，評估對生產的影響，從而優化決策方案³⁴。

對於半導體廠務系統，數位分身的應用場景如：建立整個空調冷卻循環的數位模型，模擬不同負載下的溫度壓力分佈，以預測哪種條件易引發故障；又或者構建電力系統的數位分身，模擬開關跳脫或供電中斷時對其他設備的影響，提前制定應對措施。通過這種**虛實融合**，工程師可以對系統有更深入的理解。同時，數位分身也為模型提供了**高品質的合成數據**來源，前述我們提到可用模擬生成故障數據，正是數位分身的一大價值。

然而，需要指出的是，構建高精度的數位分身往往成本高、周期長，尤其對複雜的廠務系統需大量專家知識與驗證。因此目前業界應用仍以試點為主，未大規模普及。我們預期在本產品的初始版本中，數位分身相關功能將作為**附加模組**供有需求的客戶選擇，而非核心主軸。我們的研發團隊可先在特定子系統（例如空壓機或冷水機組）嘗試搭建簡化的數位分身，用於輔助強化學習決策環境或提供額外的故障機理判斷。隨著技術成熟，我們再考慮將數位分身更緊密地融入PHM產品鏈。

總之，數位分身代表了PHM的未來發展方向，它有望進一步提高預測的準確性和決策的可靠性³⁵³⁶。在本報告中我們將其納入研發清單，鼓勵團隊關注相關前沿論文和工具，但在產品路線上會審慎評估其投入產出，比較務實地把握其作為輔助的角色。

總結

本報告提出了一套面向半導體廠務系統的**先進PHM產品鏈設計**。我們從感測器開始，經由異常偵測、故障診斷、剩餘壽命預測，直到維護決策支援，構築起一條龍的智慧維護流程。同時考慮了資料品質、模型泛化、系統架構和人機介面的各個層面。透過引入**最新深度學習技術**（如少樣本異常偵測⁶、域自適應故障診斷、深度RUL預測¹⁵、強化學習維護優化²³等），我們在每個環節都找出了可供參考的前沿研究方法作為技術儲備。同時也納入**傳統方法**作為對照（如規則診斷、統計預測、優化調度），以確保研發有扎實的基準，最終產品能兼顧創新性與可靠性。

這份研究清單將指引研發團隊逐步攻克各項關鍵技術難題。例如，先解決感測器漂移校正以獲得穩定數據，再研發強健的異常偵測算法。隨後，可並行展開故障診斷與預測模型研發，最後整合至決策系統和架構部署。同時在研發過程中持續關注模型在不同場景的**泛化表現**，並利用儀表板KPI來驗證改進。雖然完整落地需要多學科協作與反覆驗證，但本報告已表明此方向的巨大潛力：預期導入本PHM解決方案後，可實現**零非計畫停機**或將其機率降至最低，並優化維護資源配置¹。對晶圓廠而言，這將轉化為生產效率的提升和營運成本的降低。

未來，我們也將持續關注新興技術，如數位分身深化應用、聯邦學習保障數據隱私、以及更高階的自主維護機器人等，適時將其納入產品藍圖。總的來說，本報告為半導體廠務PHM產品指明了前沿發展路線，我們有信心隨著研發的推進，該產品鏈將成為智慧製造領域的重要里程碑，為工廠帶來實質效益並保持競爭優勢。

參考文獻：本報告中引用的論文和資料來源包括但不限於以下：（按照出現順序）

- Hu, K. 等 (2025). An enhanced multi-sensor calibration method for HVAC systems without prior knowledge of fault types. **Building Simulation** ² ⁴ .（多感測器校準, HVAC偏差與漂移修正）
- Huang, Y. 等 (2024). Time-series few shot anomaly detection for HVAC systems. **IFAC SAFEPROCESS 2024** ⁵ ⁶ .（少樣本異常偵測, LSTM自編碼器跨域適應）
- Azamfar, M. 等 (2020). Deep learning-based domain adaptation method for fault diagnosis in semiconductor manufacturing. **IEEE Trans. Semicond. Manufacturing**, **33**(3).（深度領域自適應, 半導體設備故障診斷泛化）
- Li, X. 等 (2024). A method for predicting remaining useful life using enhanced Savitzky–Golay filter and improved deep learning framework. **Scientific Reports**, **14** ¹⁵ ¹⁷ .（CNN+LSTM多通道壽命預測, 提升動態準確度）
- Rodríguez, M.L.R. 等 (2022). Multi-agent deep reinforcement learning based Predictive Maintenance on parallel machines. **Robotics and Computer-Integrated Manufacturing**, **78** ²³ .（多智能體強化學習, 維護調度優化75%效益提升）
- Somu, N. & Dasappa, N.S. (2024). IntelliPdM: An end-to-end IIoT predictive maintenance framework on edge-cloud platform. (SSRN preprint) ²⁸ .（Edge-Cloud架構, 異質資料即時處理與儀表板）
- Van Dinter, R. 等 (2022). Predictive maintenance using digital twins: A systematic literature review. **Information and Software Technology**, **151**（數位分身預測維護的研究綜述）³³ ³⁵ .
- Zhong, D. 等 (2023). Overview of predictive maintenance based on digital twin technology. **Heliyon**, **9**(4), e14534.（數位孿生預維特性總覽, 即時監測與預測分析）
- Omron Industrial Automation, Predictive Maintenance Solutions 白皮書 ¹（PHM效益概述，如降低維護時間和成本，提高設備可用性）

（以上僅列出部分引用來源，完整文獻清單請參見報告內嵌引用）¹ ³ ⁷ ¹⁰ ²⁸

¹ Predictive Maintenance Solutions

https://www.ia.omron.com/data_pdf/cat/predictive_maintenance4_y239-e1-01.pdf?id=3686

- 2 3 4 An enhanced multi-sensor calibration method for heating, ventilation, and air conditioning systems without prior knowledge of fault types | Building Simulation
https://link.springer.com/article/10.1007/s12273-025-1272-4?error=cookies_not_supported&code=2c739b93-95f2-4d01-a059-dc5230a5f8e8
- 5 6 7 Time-Series Few Shot Anomaly Detection for HVAC Systems | VALIANT | Vanderbilt University
<https://www.vanderbilt.edu/valiant/2024/09/22/time-series-few-shot-anomaly-detection-for-hvac-systems/>
- 8 Deep learning in fault detection and diagnosis of building HVAC ...
<https://www.sciencedirect.com/science/article/pii/S2666546823000071>
- 9 Fault Detection Diagnostic for HVAC Systems Via Deep Learning ...
https://www.researchgate.net/publication/353497566_Fault_Detection_Diagnostic_for_HVAC_Systems_Via_Deep_Learning_Algorithms
- 10 Deep learning-based domain adaptation for a generalized detection ...
<https://www.sciencedirect.com/science/article/pii/S2213846323000627>
- 11 Xiang Li's Homepage - Publications - Google Sites
<https://sites.google.com/view/xiang-li/publications>
- 12 Fault Detection in Semiconductor Etching Processes - AZoM
<https://www.azom.com/article.aspx?ArticleID=21745>
- 13 14 15 16 17 18 A method for predicting remaining useful life using enhanced Savitzky–Golay filter and improved deep learning framework | Scientific Reports
https://www.nature.com/articles/s41598-024-74989-y?error=cookies_not_supported&code=2bd690f6-68fd-47a4-91a3-591a2aa92d0d
- 19 Remaining useful life with self-attention assisted physics-informed ...
<https://www.sciencedirect.com/science/article/abs/pii/S1474034623003233>
- 20 Accurate and efficient remaining useful life prediction of batteries ...
<https://www.sciencedirect.com/science/article/pii/S2095495624000214>
- 21 22 23 24 25 (PDF) Multi-agent deep reinforcement learning based Predictive Maintenance on parallel machines
https://www.researchgate.net/publication/361865416_Multi-agent_deep_reinforcement_learning_based_Predictive_Maintenance_on_parallel_machines
- 26 27 28 29 30 An Edge-Cloud Iot Framework for Predictive Maintenance in Manufacturing Systems by Nivethitha Somu, Nirupam Sannagowdara Dasappa :: SSRN
https://papers.ssrn.com/sol3/papers.cfm?abstract_id=4932094
- 31 32 33 34 35 36 (PDF) Applications of Digital Twins in Predictive Maintenance of Mechanical Systems
https://www.researchgate.net/publication/388414391_Applications_of_Digital_Twins_in_Predictive_Maintenance_of_Mechanical_Systems